

Splay tree の解説

Splay tree は平衡二分探索木(BST)の一種で, look up, insert, delete, merge, split などの操作をなし $O(\log n)$ で行うデータ構造(特長). 各ノードの key と値のペアを保持すれば十分なのでメモリの意味で優れています。
(STOC '83) で Sleator, Tarjan が発表


“self-adjusting”… よくアクセスされるノードは根に近いつまりアクセスしやすい位置にささげられ変形されるため、偏ったデータなどに対する効率化

- なさない最悪の場合 $O(n)$ time かかります。漸近的に
- “self-adjusting”の恩恵で情報理論的な意味で全体の計算量が最適

メインの操作: Splay ($\Theta(1)$) -- x を根にする。


Splay(x)では x , x の親, x の親の親の位置関係に基づき次の3つの操作を繰り返して x を根にす。

(I) zig-step (x の親の親がない場合)




2通り

(例)




\Downarrow Splay(E)

(II) zig-zig-step ($(x, p), (p, q), (q, r)$ の位置関係が同じ)



2通り

(III) zig-zag-step (その他)




2通り

(I), (II), (III) 大きな関係が変わると保たれてる
ことに注意!


Splay tree の解析

Splay (α) を行うことでの頂点を右にするとその周りの部分木も深さが小さくなっているのがポイント。(部分木の深さが減るとその部分木内全の頂点の深さが 1 増えることになる。)
(操作パート)

- Lookup (α) ... 上から木上を探査し最終的に見つけた頂点を返すと, Splay (α) を行う。
(存在する $x = \alpha$)
- Insert (α) ... 上から木上を探査し適切な場所に挿入し, Splay (α) を行う。
(例)



- Delete (α) ... Lookup (α) を行い, 根である頂点を削除し残りの2つの部分木をマージする。



merge, split も同様ができる。

(解析パート) 結局のところどの操作も O(1) 回の Splay 操作を行えること等しい。
Splay 操作のみ考慮。(木上の探索は Splay 操作 1 回の計算量で明かにバウンドされる)

(Tips)

実は Splay tree の解析はかなり難しく, 未だに未証明の conjecture いくつか存在す。

ただし計算量といふことはボテンシャルを定めた。

$\sum_{i=1}^n w_i l_i$ と定め, 各ノードの根からの距離を l_i , 各ノードを根とする部分木の重みを w_i とする。

正規化後 i の rank(i) の和をボテンシャルとする。

$$S(\alpha) = \sum_{x \in \text{木の根を除く部分木}} w_i \quad \text{となる}, \quad \sum_{x \in \text{木}} S(x) = \sum_{i=1}^n w_i l_i + \sum_{i=1}^n w_i \quad \text{となる}.$$

w_i は後の Optimality の証明用
あれ各種の出現確率が対応するもの
導入しておく。

Splay tree の解析

また x の rank, $r(x)$ を

$$r(x) \stackrel{\text{def}}{=} \log S(x) \text{ と定め, } \Phi = \sum_{i=1}^m r(x_i) \text{ と定める}$$

ここで zig, zig-zig, zig-zag の各操作を繰り返しで行われる Splay (ℓ) の操作回数から

なげしコストは $3(r(\alpha) - r(\alpha)) + 1$ 以下であることを示す。(これは木の根である)

実際のかかる計算量 (特に zig は $3(r(\alpha) - r(\alpha)) + 1$ 以下; zig-zig, zig-zag は $3(r(\alpha) - r(\alpha)) + 1$ 以下)

+ ポテンシャル部分 (注) なげし解析(ポテンシャルを用いた場合)は m 回の操作回数 —

$$\sum_{i=1}^m \alpha(\text{op}_i) = \sum_{i=1}^m t(\text{op}_i) + O(1) \cdot (\Phi_m - \Phi_0)$$

なげしコストの和 実際のかかる計算量 最初と最後のポテンシャルの差

(Proof)

(i) Zig の場合

以下の議論は 2通りの zig の両方に対応している。

$r'(x) \geq r(p), r'(p) \leq r(x)$ かつ Φ (シルバートランク) が変化しないより

$$(\text{なげしコスト}) = 1 + \Delta \Phi = 1 + r'(x) + r'(p) - r(x) - r(p)$$

$$\quad \quad \quad \text{1回転操作量} = 1 + r'(p) - r(x)$$

$$\leq 1 + r'(x) - r(x)$$

$$\leq 3(r'(x) - r(x)) + 1$$

(ii) zig-zig の場合 以下の議論は 2通りの zig-zig の両方に対応している。

$$(\text{なげしコスト}) = 2 + \Delta \Phi = 2 + r'(x) + r'(p) + r'(g) - r(g) - r(p) - r(x)$$

$$= 2 + r'(p) + r'(g) - r(p) - r(x) \leq 3(r'(x) - r(x))$$

結局 $r'(p) + r'(g) - r(p) - r(x) - 3r(x) + 3r(x) \leq -2$ となる。

$$\textcircled{1} = r'(p) + r'(g) - r(p) - 3r(x) + 2r(x)$$

$$\leq r'(x) + r'(g) - r(x) - 3r(x) + 2r(x)$$

$$= r'(g) - r(p) - 2r(x) + 2r(x)$$

$$\leq r'(g) - r(x) - 2r(x) + 2r(x)$$

$$= r(x) - r(x) + r(g) - r(x)$$

$$= \log \frac{S(x)}{S(x)} + \log \frac{S(g)}{S(x)}$$

ここで $x > 0, y > 0, x+y \leq 1$ なら
 $\log x + \log y \leq -2$ なり、
手せた。

$$\begin{aligned} & \because \log x + \log y \leq \log xy \\ & \leq 2 \log \frac{x+y}{2} \\ & = -2 \end{aligned}$$

Splay tree の解析

(iii) zig-zag の場合 zig-zig と同様である。

(i) ~ (iii) より α が根なるまで zig, zig-zig, zig-zag を繰り返していくにかかる総コストは高々 $3(V_m - V_n) + 1$ である。
 (zig は最後に高々 1 回行われる。)

最後に全体でのポテンシャルの減少分を bound する $W = \sum_{i=1}^n W(\alpha_i)$ すると、
 $\log W_i \leq V(\alpha_i) \leq \log W$

より $H(\alpha_i)$ の減少分は高々 $\log W - \log W_i$ 。

ゆえに全体で $n \log W - \sum_{i=1}^n \log W_i$ である。

Theorem. n 頂点のスプレイ木 M 固の操作を行ったときの計算量は $O(m \lg h + h \lg n)$

Proof. $W_i = \frac{1}{n} (i-1, -n)$ と定めよ ($2 \leq V(\alpha) \geq \log \frac{1}{n} = -\lg n$ 注意)

各操作が前述のように $O(n)$ 回の Splay 操作にかかる計算量は n で bound されるので、結局 $O(m)$ 回の Splay 操作にかかる計算量を考えればよい。

$$\begin{aligned} \text{すると } \sum_{i=1}^m t(\alpha_i) &= \sum_{i=1}^m A(\alpha_i) + O(1) \cdot (\bar{\Phi}_0 - \bar{\Phi}_m) \\ &\leq \sum_{i=1}^m (3(V_m - V_i) + 1) + (n \log W - \sum_{i=1}^n \log W_i) \\ &= O(m \lg h) + O(h \lg n) \quad (\because V_i = 0, \\ &\quad V_{0,2} = \lg h) \end{aligned}$$

Static Optimality の話

Fix した二分探索木 (BST) の構築を考える。

どの Key が Lookup される確率の分布が予め分かっているとき最適な BST
 (期待計算量が最小)

直感的には 3 モード分割 (よくアセスメントでは根の近くに分ける)

($O(n^2)$ time のアルゴリズムが存在)
 (Knuth '71)。

$O(n^3)$ の DP を書く Knuth Optimization と呼ばれてる (SPLICE)

Splay tree の解析

225 期待計算量の下限と有名な定理について説明する。

Theorem. Static Optimality

要素 (x_i, p_i) が確率 p_i でアクセスされる確率を π_i とする最適な BST の期待計算量は

$$\sum_{i=1}^n (-\pi_i \log p_i + 1) \text{である (つまり, } \sum_{i=1}^n (1 + H))$$

$\sum_{i=1}^n -\pi_i \log p_i$ は Shannon entropy と呼ばれる。基本 H を表すことが多い。

(上記の定理は各要素が一度でも一度はサンプルされるとき、全ての Lookup が成功するまで反復する。)

226 Splay木は事前に出現確率を知らないときに $O(1+H)$ の計算量を達成する。

言い換えると、Splay木は (x_i, p_i) に対して最適な動的 static-BST に対して定数倍か大きく遅くならない。(ならしの意味)

↑ 動木と比べて偏りがある時

$O(\log n)$ time かかり得る。

(Proof.) 先ほどの式を式が $3h(\pi) - h(\pi_i)) + 1 \leq -3 \log p_i + 1$ である,

$$\begin{aligned} \sum_{i=1}^m t(\text{op}_i) &= \sum_{i=1}^n m p_i (-3 \log p_i + 1) + h \log W - \sum_{i=1}^n \log W_i \\ &\stackrel{\text{左辺}}{=} \sum_{i=1}^m a(\text{op}_i) \quad O(1) \cdot (m - \#) \\ &\leq (m + 3mH) + mH \\ &= O(m + mH) \end{aligned}$$

つまりならし $O(1+H)$ 。

• Dynamic Optimality Conjecture の話

各要素の順序列 $X = \{x_1, \dots, x_m\}$ に対して最適な動作を BST $T(X)$ とする。

ここで Splay木は $T(X)$ に対して定数倍か大きく遅くならないといふ仮説。

しかし、competitive ratio が $O(1)$ であるといふ仮説。

($O(1)$ の competitive ratio を達成する BST が存在するかどうかは未定義)

$O(\log \log n)$ factor のものは知らぬ。

(Tango tree & multisplay tree)
(04) (06)